Optimizing Homomorphic Encryption in Federated Learning with Zero-Skipping

컴퓨터.전자시스템공학부
201900532 김건하

Background

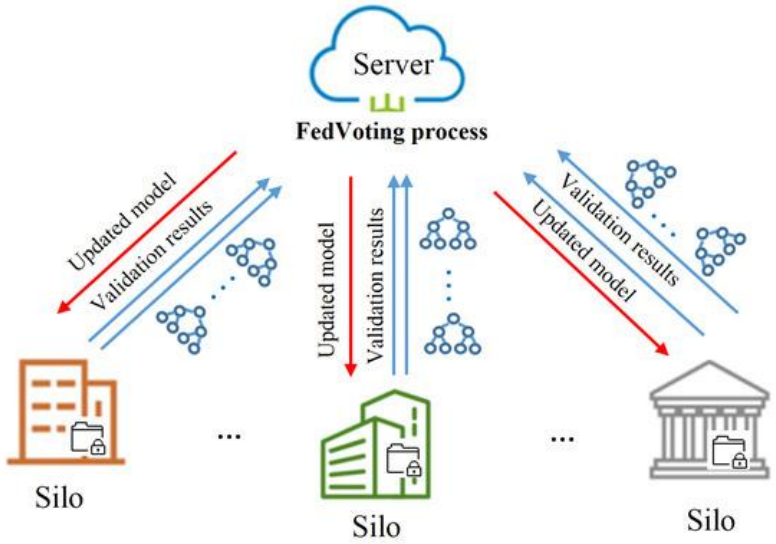

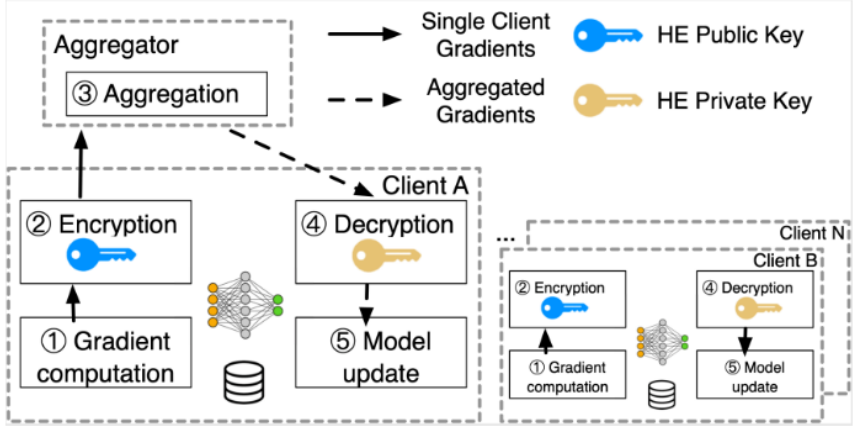

- Cross-silo Federated Learning
  - 여러 기관/조직(병원, 기업, 은행 등)에서 협력적 모델 학습
  - 예) 병원 간 의료 데이터 학습, 은행 간 거래 분석
  - 기관 간 데이터 보호와 보안 중요
  - gradient inversion

- Homomorphic Encryption
  - 암호화된 데이터를 서버에 보내 복호화 없이 직접 연산 가능
  - Privacy 보호 가능, 정확도 손실이 없다
  - 암호화 과정에서 계산 및 통신 비용이 매우 크다
  - FL 대부분의 시간을 HE에 사용, bottle neck 발생

Previous Work

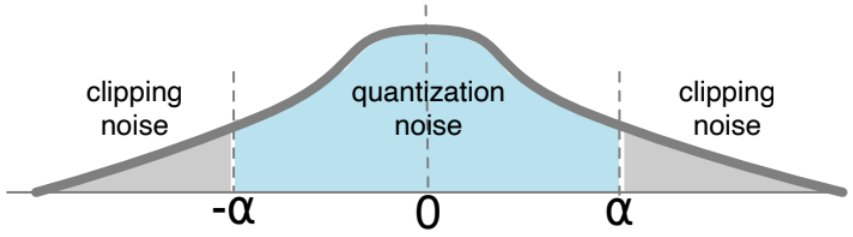

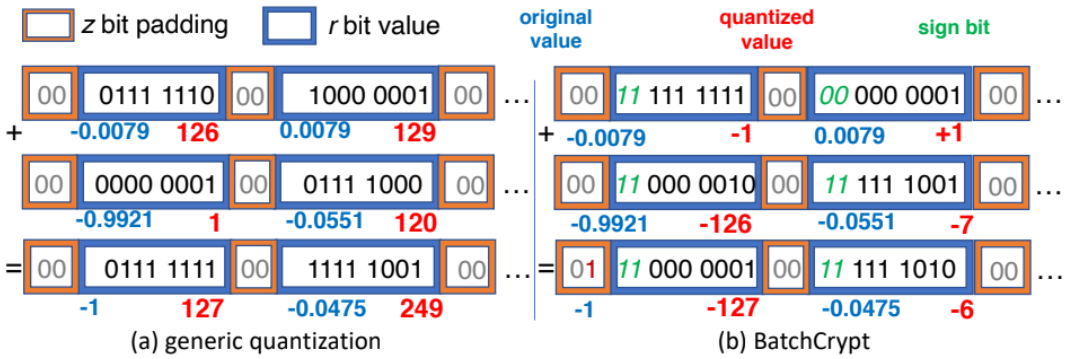

- BatchCrypt
- Quantization과 Batching으로 HE 연산 비용 감소
- 여러 gradient를 하나의 긴 정수로 인코딩
- HE 호출 횟수 감소
- 통신 비용 및 훈련 속도 개선

Approach

- Quantization size가 작을수록 0의 비율이 높아지는 것에 주목
- 하나의 Batch가 모두 0이면 Encryption 생략
- Quantization size가 너무 작으면 원본 Gradient 값 손실로 인해 Accuracy 손실

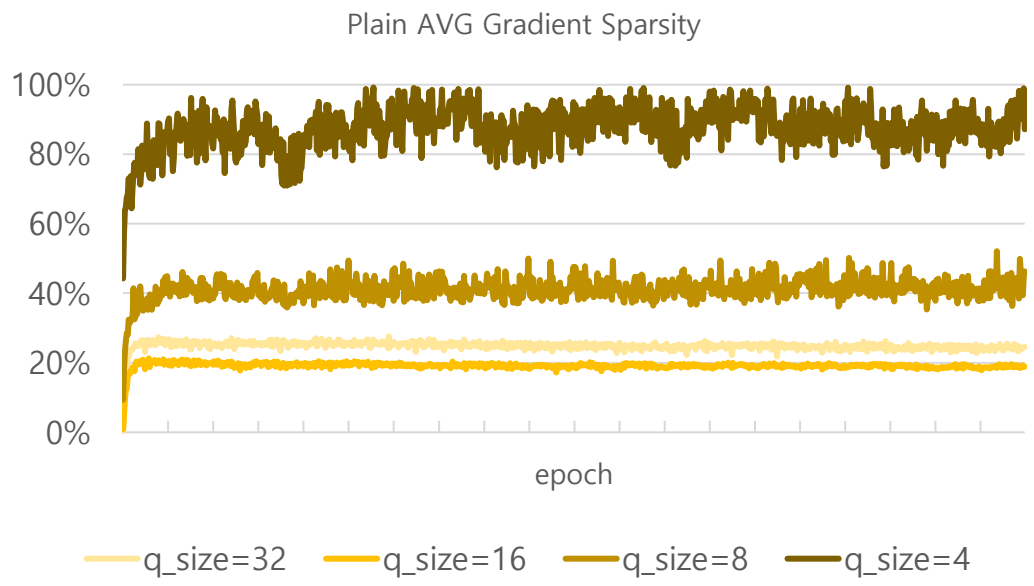

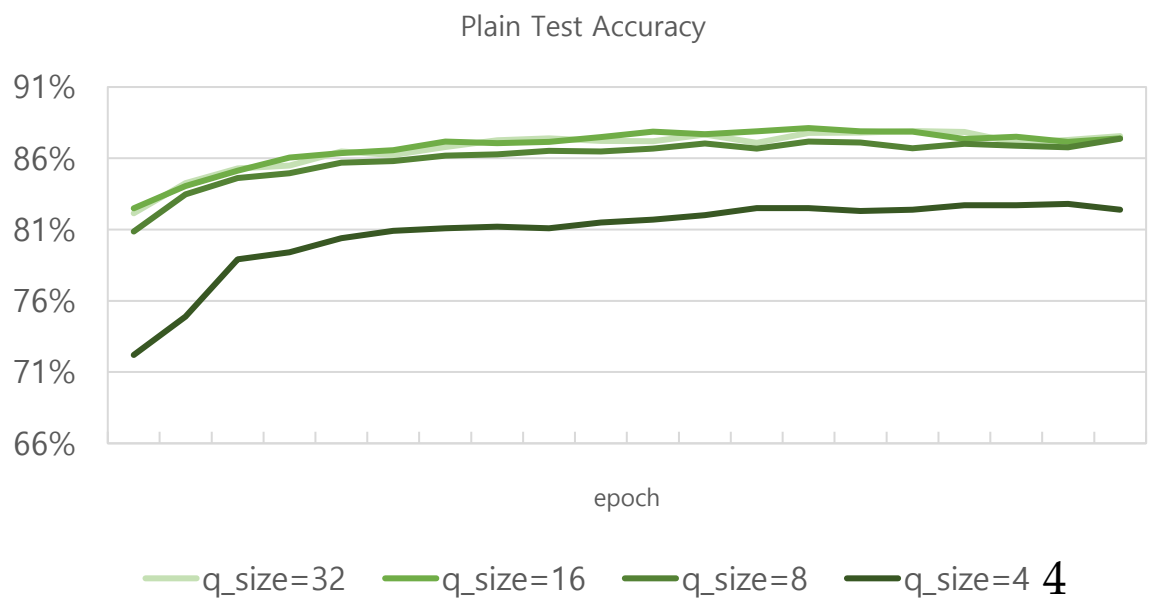

Proposed Method

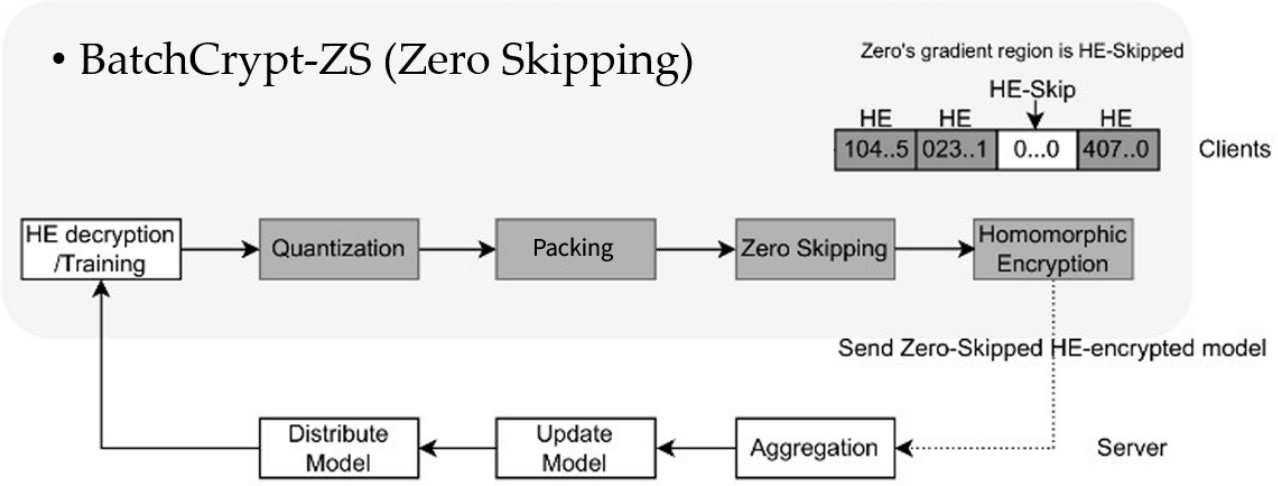

1. Quantization & Packing

- 연속값 gradient를 quantization 후 batch_size 단위로 하나의 큰 정수로 pack

2. Skip Decision

- skip_mask를 이용하여 skip block을 기록

3. Homomorphic Encryption

4. Aggregation & Update Model

- Client가 skip mask를 함께 서버로 전달
- 서버는 skip mask의 index 기준으로 각 client의 encrypted block 들을 aggregation 수행
- Skip된 block은 상수로 계산된 enc(0) 값을 사용하여 중복 계산 방지

5. Decryption

- 원본 gradient로 복원

Experiment Environment

구분	내용
Dataset	Fashion-MNIST
Model	단층 CNN
Client 수	10 명
Quantization bits	8-bit, 4-bit 정수 양자화
Zero-Skipping	블록 단위 zero block skip 적용
Metric	학습 시간 / 암호화 시간 / test accuracy

- 암호화 연산 감소 효과를 측정하기 위해 연산량이 적은 모델 사용
- 비교대상:

1. BaseLine: BatchCrypt
2. Proposed: BatchCrypt Zero-Skipping

Result

- 암호화 단계에서 직접적인 연산량 감소로 계산 및 통신 비용 절감
- q_size=8, q_size=4에서 각각 전체 학습시간 약 **30%, 70%** 감소
- q_size=8, q_size=4에서 각각 test accuracy **87.5%, 85.8%**로 유지

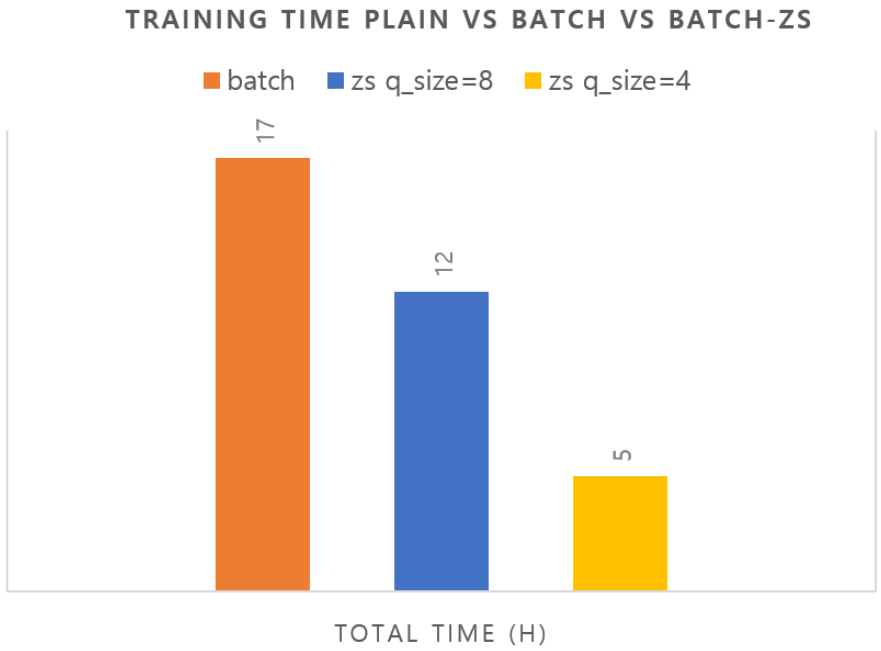

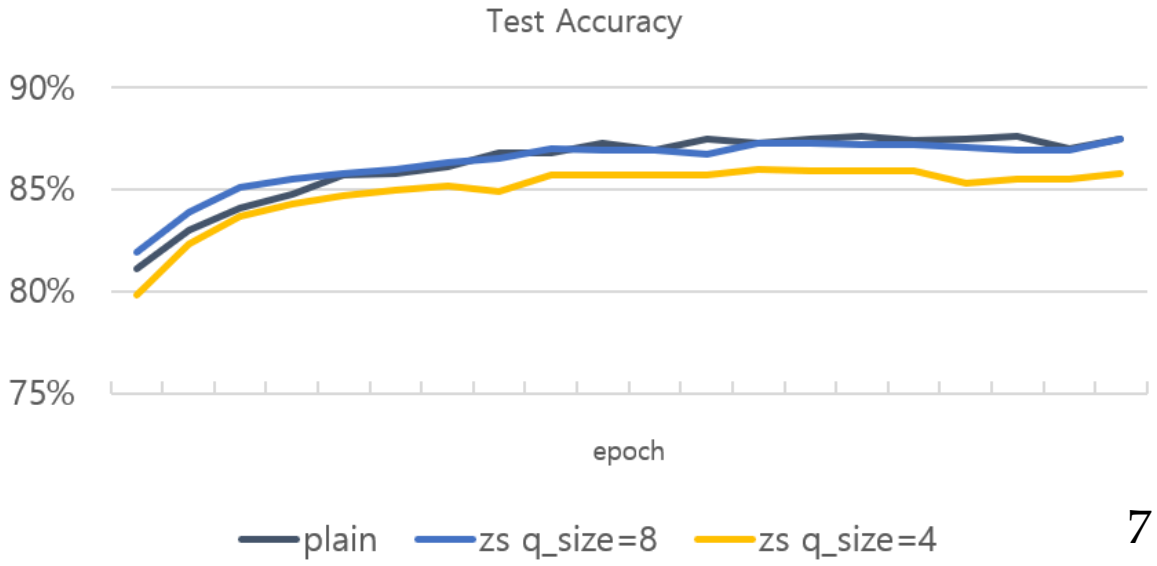

Conclusion & Further Study

- Quantization으로 인한 정확도 저하는 **1~3%** 미만으로 유지하며 계산 비용을 **30~70%**로 크게 절감
- skip ratio **40~60%**에 비례하여 통신비용 절감

- 복잡한 모델에 대해 성능 검증
- batch size와 skip 기준 임계치를 동적으로 부여해 결정

Q & A